

Анализ ошибок датасета для модели v0

1. Сильная несбалансированность длины текстов.

Пример датасета можно посмотреть на github :

[Fine-tuning-LLM/Course_work/src/dataset.json at main · ElizaTTN/Fine-tuning-LLM](#)

Данный датасет получился несбалансированным так как тексты разных стилей имеют разные объемы (художественный - ~23 500 символов (~5 900 токенов) , научный - ~16 000 символов (~4 000 токенов), публицистический - ~4 800 символов (~1 200 токенов)).

Предварительные предсказания проблем :

во время обучения модель минимизирует loss по токенам, а не по примерам. Если художественный текст содержит: 3000 токенов, а новость: 300 токенов, то один художественный пример весит как 10 новостей. Модель фактически учится почти только на художественном стиле.

Последствия

- стили смешиваются
- появляются длинные циклы
- модель начинает генерировать огромные абзацы

Как решить:

1. Нормализовать длину. Необходимо разбить длинные тексты на равные чанки. Минимальная оптимальная длина 100–300 токенов.
2. Сбалансировать стили. Необходимо одинаковое количество токенов на стиль.

2. Разная лексика

В художественном стиле используется старорусский.

Например:

- «ибо»
- «пополудни»

- «оная»
- «дабы»

А публицистика — современная. Это создаёт конфликт языковых распределений. Модель начинает ломать синтаксис.

Решение:

избавиться от классической русской литературы и использовать современные рассказы. Например: современная проза (короткие рассказы, современная художественная публицистика, диалоговые сцены), сценарии фильмов или пьес.

3. Неправильный выбор источника

В качестве источника для научного стиля был выбран habr.com. Это блогерский стиль, а не научный, в тексте встречается много информации в стиле :

- "Привет, я Данила Трусов, директор продукта «Инферит ИТМен».Хочу рассказать,"
- "Всем привет, это Тимур."
- "🔥 Что такое Kimi K2 и чем она отличается от обычной KimiMoonshot AI позиционирует Kimi K2 как следующее поколение ассистента, а не просто модернизацию.Ключевые особенности:новая архитектура, оптимизированная под длинные контексты;улучшенный reasoning;ускоренная генерация;улучшенный анализ кода;мультимодальность;поддержка огромных вложений;перевод высокого качества на русский, английский и китайский. 📌"

Научный стиль должен быть без:

1. первого лица
2. обращений
3. разговорной структуры
4. смайликов

В качестве источника для публицистического стиля были взяты новости, что вызывает проблемы так как новости слишком короткие и шаблонные.

Решение :

1. Для научного стиля лучше поменять источник и выбрать аннотации научных статей, методички, учебники. (eLIBRARY, CyberLeninka, arXiv.
2. Для сбора данных публицистического стиля так же изменить источник в пользу авторских колонок (аналитические статьи, развернутые мнения), лонгриды (эссе, разборы, интервью).

Также для всех трех стилей обратить внимание на формат :

- одинаковая длина чанков (например 100–300 токенов)
- одинаковое количество токенов на стиль
- отсутствие метатекста
- отсутствие html, ссылок, кода (что было в статьях с хабра)

4. Проблема с промтами

В данном случае промты выглядят таким образом:

- *"Создай натуралистичное описание..."*
- *"Составь документ..."*
- *"Необходимо разработать содержательный материал..."*

Для создания промтов была использована функция, которая предлагает разные формулировки запроса для разных стилей.

Пример для публицистического стиля приведен ниже.

```
# Инструкции для формирования датасета
self.prompt_templates = [
    "Напиши новостную заметку на тему: {title}",
    "Подготовь краткий обзор новости: {title}",
    "Составь информационную сводку: {title}",
    "Опиши ключевые аспекты материала: {title}",
    "Подготовь публикацию для СМИ по теме: {title}"
]
```

Пример для научного стиля :

```
prompts = [
```

```

    f"[СТИЛЬ: {random.choice(style_variants).capitalize()}]
{random.choice(action_variants)} {random.choice(format_variants)} на тему:
{title}",
    f"{random.choice(action_variants)} {random.choice(format_variants)} в
{random.choice(style_variants)} стиле: {title}",

    f"Как эксперт в области {' '.join(categories[:2]) if categories else
'технологий'} {random.choice(action_variants).lower()}
{random.choice(format_variants)}: {title}",

    f"Требуется подготовить {random.choice(format_variants)} по теме:
{title}",
    f"Необходимо разработать содержательный {random.choice(format_variants)}
на тему: {title}",

    f"Проведи исследование и напиши {random.choice(format_variants)} на тему:
{title}",
    f"Проанализируй текущее состояние вопроса и подготовь
{random.choice(format_variants)}: {title}",

    f"Создай образовательный {random.choice(format_variants)} для специалистов
по теме: {title}",
    f"Подготовь развернутый {random.choice(format_variants)} для изучения
темы: {title}",

    f"Разработай практический {random.choice(format_variants)} с
рекомендациями по теме: {title}",
    f"Создай руководство для профессионалов: {title}",
]

```

Это разные форматы инструкции. Модель учится не только стилю, но и структуре инструкции, поэтому лучше унифицировать.

Решение :

Унифицировать промты. Пример представлен ниже.

"Напиши текст в [СТИЛЬ] стиле на тему: ..."

5. Слишком маленький датасет

Размер датасета составил 3000 примеров, что мало для обучения LLM.

Решение :

1. Увеличить корпус до 10К.

2. Англоязычный корпус (10к экземпляров). Работа будет производиться экспериментально:

– Эксперимент 1 – **Монолингвальная адаптация**
10k RU

Цель: посмотреть базовое качество модели.

– Эксперимент 2 – **Билингвальная адаптация**
10k RU + 10k En

Цель эксперимента : влияет ли английский корпус, ухудшается ли русский, ответить на вопрос "Способна ли модель логично переключаться с русского на английский и обратно" (тк при тестировании прошлой модели (только на русском корпусе) были выбросы текстов на английском.)

Можно ответить на вопросы:

Влияет ли добавление английского корпуса на качество генерации русскоязычных текстов?

Снижает ли билингвальное обучение вероятность генеративной рекурсии?